中小型表格分类任务上表格基础模型与 Boosted-Tree Baseline 的比较

> 学习用中文版本。本文保持英文报告的实验结论、数字、图表引用和方法口径不变，只把正文改写成便于理解的中文表述。正式提交仍建议以英文版为准。

摘要

本项目在两个 OpenML 表格分类数据集 Adult 和 Bank Marketing 上，比较了两个表格基础模型 TabPFN v2、TabICL，以及两个强 boosted-tree baseline：LightGBM 和 XGBoost。评估采用 repeated stratified splits，并报告 accuracy、balanced accuracy、macro-F1 和实际运行时间。主线结果显示，boosted-tree baseline 在 Adult 上仍然最强，而基础模型，尤其是 TabICL，在 Bank Marketing 上更有竞争力。运行时间结果显示出明显的实际成本差距：树模型快得多，TabICL 明显快于 TabPFN v2，并且基础模型的运行时间会随着训练集规模增大而上升。

作为 Big Plus 扩展，本项目还在 Adult 上研究了 TabICL 的支持集选择。实验把三个预算受限的支持集策略与 full-context 参考结果进行比较。冻结版本的 balanced prototype retrieval 策略没有超过 random subset 或 balanced random subset，但预算受限支持集显著降低了 TabICL fit+predict 的模型侧运行时间。因此，Big Plus 结果更适合被解释为一个有价值的负结果 ablation：支持集压缩在实践上有用，但当前基于类别中心的 prototype retrieval 规则不是一种能提升预测表现的方法。

引言

表格数据仍然是应用机器学习中的核心数据类型，常见于金融、营销、医疗和运营等场景。Boosted-tree 方法至今仍是表格预测任务中的强默认选择；与此同时，tabular foundation models 希望通过更广泛的复用能力和更少的任务特定建模工作，成为新的候选方案。本项目关注一个实际问题：在受控的本地实验中，表格基础模型什么时候看起来优于 boosted-tree baseline？这种优势又需要付出多少运行成本？

本项目主线范围是中小型表格数据集上的分类任务。回归和生存分析不在本项目范围内。主线比较包括四个模型：LightGBM、XGBoost、TabPFN v2 和 TabICL。主要数据集是 Adult 和 Bank Marketing。报告关注三个预测指标，也就是 accuracy、balanced accuracy 和 macro-F1，同时也关注 runtime。

项目还包含一个围绕 TabICL 的小型 Big Plus 扩展。因为 TabICL 会把支持样本作为上下文使用，所以支持集选择是一个相对独立、范围清楚的方法扩展方向，可以用来研究更好的上下文构造是否能改善指标和运行时间之间的 tradeoff。这个扩展与主线比较分开处理，这样即使 Big Plus 方法没有提升性能，主线报告仍然是有效的。

本项目的研究问题包括：

- 在 Adult 和 Bank Marketing 上，哪一类模型表现最好？
- 随着 train size 增大，accuracy、balanced accuracy 和 macro-F1 如何变化？
- 实际运行时间如何随 train size 扩展？
- TabICL 是否适合作为一个小型方法扩展的基础模型目标？
- TabICL 支持集选择能否改善指标和运行时间之间的 tradeoff？

相关工作与背景

Boosted-tree 模型广泛用于表格学习，因为它们能较好处理异构特征、训练速度快，并且通常在有限调参下也有很强表现。本项目中，LightGBM 和 XGBoost 被用作 fixed strong baselines，而不是经过大量调参的 state-of-the-art baselines。它们提供了实际比较基准，用来判断基础模型是否值得付出额外成本。

表格基础模型的目标是在不同表格预测任务之间复用学习到的结构。TabPFN v2 是一种面向表格预测的 prior-data-fitted model。TabICL 则以 in-context learning 的方式组织表格预测，因此支持样本的选择尤其重要。本项目把这些基础模型当作本地可用的实际工具来评估，而不是把它们当作外部 benchmark suite 上的冠军模型来讨论。

Accuracy 容易理解，但它可能掩盖少数类表现。这个问题在 Bank Marketing 上尤其重要，因为类别不平衡会让单看 accuracy 变得不充分。因此，报告加入 balanced accuracy 和 macro-F1 作为补充指标。Runtime 也是评估的一部分，因为一个模型即使准确，如果太慢，在实际中也可能很难使用。

本项目没有使用 TALENT、TabArena 或其他外部表格 benchmark suite。所有报告结果都来自所选 OpenML 数据集上的本地实验。

数据集

本项目使用两个 OpenML 分类数据集。

Adult 是一个二分类收入预测数据集，包含 48,842 个样本、14 个原始特征，其中 6 个是数值特征，8 个是类别特征。它混合了数值列和类别列，并包含缺失值。数据加载器会把 `?`、`NA`、`null` 等常见字符串缺失标记统一规范成 missing values，再进入各模型自己的预处理流程。在主线结果中，Adult 整体上更偏向 boosted-tree baselines，尽管 TabICL 接近最强树模型。

Bank Marketing 是一个类别不平衡更明显的二分类数据集。它可以检验 balanced accuracy 和 macro-F1 是否会给出不同于 accuracy 的结论。这个数据集中的 `unknown` 被保留为观察到的类别取值，而不是被自动当成缺失值。在主线结果中，foundation models 在这个数据集上更有竞争力，并且 TabICL 有最强的不平衡类别相关指标。

实验采用 repeated stratified splits。在每个 seed 内，所有模型共享同一个 train/test split。跨 seeds 时，测试集会变化；因此这些结果是 repeated splits，而不是所有 seeds 复用同一个固定测试集。主线实验使用 seeds 42、43、44、45 和 46。Phase 6 Big Plus Adult 实验使用 seeds 42、43 和 44。

方法与模型

LightGBM 被用作快速 boosted-tree baseline。它在 Adult 上表现强，并且在不同 train sizes 下都保持高效率。

XGBoost 被用作第二个 boosted-tree baseline。它同样快速且强，在主线结果中拥有 Adult control-10k 的最高 accuracy，不过并不是每个指标上都最高。

TabPFN v2 被用作 tabular foundation-model baseline。它在一些小训练集规模设置下有竞争力，但比树模型慢，也比 TabICL 慢。Full-train TabPFN v2 行应当被视为 constrained reference results，因为它们超过了主控比较中更干净的 10k support-range 口径。

TabICL 是第二个表格基础模型。它在 Adult 上接近树模型，在 Bank Marketing 的不平衡类别指标上最强。在本地设置中，它也明显快于 TabPFN v2，因此自然成为 Big Plus 支持集选择 ablation 的目标模型。

实验设置

主线比较在 Adult 和 Bank Marketing 上评估 LightGBM、XGBoost、TabPFN v2 和 TabICL。实验使用两个主要场景：

- `control_10k`：使用 10,000 个训练样本的受控比较。
- `full_train_reference`：使用完整可用训练 split 的工程参考结果。

Scalability analysis 评估 train sizes 512、2048、8192、10000 和 full。主线均值和标准差基于 seeds 42、43、44、45 和 46 计算。

评估指标包括：

- Accuracy。
- Balanced accuracy。
- Macro-F1。
- Fit seconds、predict seconds 和 total seconds。

Runtime 数值是实际 mixed-device timings。树模型在 CPU 上运行，而 foundation models 可能使用 CUDA。因此，runtime 应被解释为实际本地运行成本，而不是严格的同设备硬件 benchmark。

LightGBM 和 XGBoost 是 fixed strong baselines。它们不是调参后的 state-of-the-art baselines。这个选择使项目聚焦于一个受控课程项目比较，而不是超参数搜索。

作为补充鲁棒性检查，本项目还在 Adult 上做了一个小型 missingness stress test：训练规模固定为 2048，seed 固定为 42，对 feature cells 注入 0%、10% 和 30% 的确定性缺失值，target labels 不变，并且四个模型共享相同的 masked split。这个检查刻意保持轻量，不应被理解为完整的 missing-value 或 categorical-cardinality robustness benchmark。

主线结果

Table 1 总结主线模型比较结果。在 Adult 上，boosted-tree models 整体仍然最强。在 `control_10k` 场景中，XGBoost 的 accuracy mean 最高，为 0.8698；LightGBM 的 balanced accuracy 和 macro-F1 最强。TabICL 接近树模型 baseline，但没有明确超过它们。TabPFN v2 在主要指标上较低，并且比树模型和 TabICL 都慢。

在 Bank Marketing 上，foundation models 更有竞争力。在 `control_10k` 场景中，TabICL 和 TabPFN v2 的 accuracy mean 同为 0.9093，但 TabICL 在 balanced accuracy 和 macro-F1 上更强。在 `full_train_reference` 场景中，TabICL 拥有最好的 accuracy、balanced accuracy 和 macro-F1。树模型仍然快得多，但它们在这个数据集上的预测指标并不领先。

Table 1 中的 metric columns 是五次 repeated stratified splits 的均值，runtime column 是同一批 seeds 上 total runtime 的中位数。

表 1. Adult 和 Bank Marketing 上的主线模型比较。

数据集	场景	模型	Accuracy	Balanced Accuracy	Macro-F1	Median Total Seconds
Adult	control_10k	LightGBM	0.8692	0.7934	0.8097	0.3147
Adult	control_10k	TabICL	0.8681	0.7909	0.8077	5.0990
Adult	control_10k	TabPFN v2	0.8614	0.7789	0.7966	13.1286
Adult	control_10k	XGBoost	0.8698	0.7887	0.8082	0.4186

数据集	场景	模型	Accuracy	Balanced Accuracy	Macro-F1	Median Total Seconds
Adult	full_train_reference	LightGBM	0.8752	0.8013	0.8183	0.8489
Adult	full_train_reference	TabICL	0.8707	0.7991	0.8133	29.7518
Adult	full_train_reference	TabPFN v2	0.8633	0.7778	0.7977	83.1503
Adult	full_train_reference	XGBoost	0.8743	0.7953	0.8150	1.2288
Bank Marketing	control_10k	LightGBM	0.9044	0.7092	0.7367	0.3133
Bank Marketing	control_10k	TabICL	0.9093	0.7397	0.7606	5.0556
Bank Marketing	control_10k	TabPFN v2	0.9093	0.7215	0.7504	13.1897
Bank Marketing	control_10k	XGBoost	0.9040	0.7019	0.7315	0.3425
Bank Marketing	full_train_reference	LightGBM	0.9083	0.7273	0.7524	0.7239
Bank Marketing	full_train_reference	TabICL	0.9119	0.7599	0.7745	20.6253
Bank Marketing	full_train_reference	TabPFN v2	0.9110	0.7209	0.7523	80.1081
Bank Marketing	full_train_reference	XGBoost	0.9083	0.7184	0.7472	0.8925

主要解释是 dataset-dependent。Adult 更偏向 boosted trees，而 Bank Marketing 给了 foundation models，尤其是 TabICL，在 imbalance-aware metrics 上更清楚的优势。Runtime column 也说明，foundation-model gains 即使出现，也要比 LightGBM 和 XGBoost 付出明显更高的实际成本。

Scalability 分析

Scalability analysis 研究当训练集规模从 512 增加到 full training data 时，指标如何变化。Figures 1 到 3 展示了 train-size grid 上的三个预测指标。

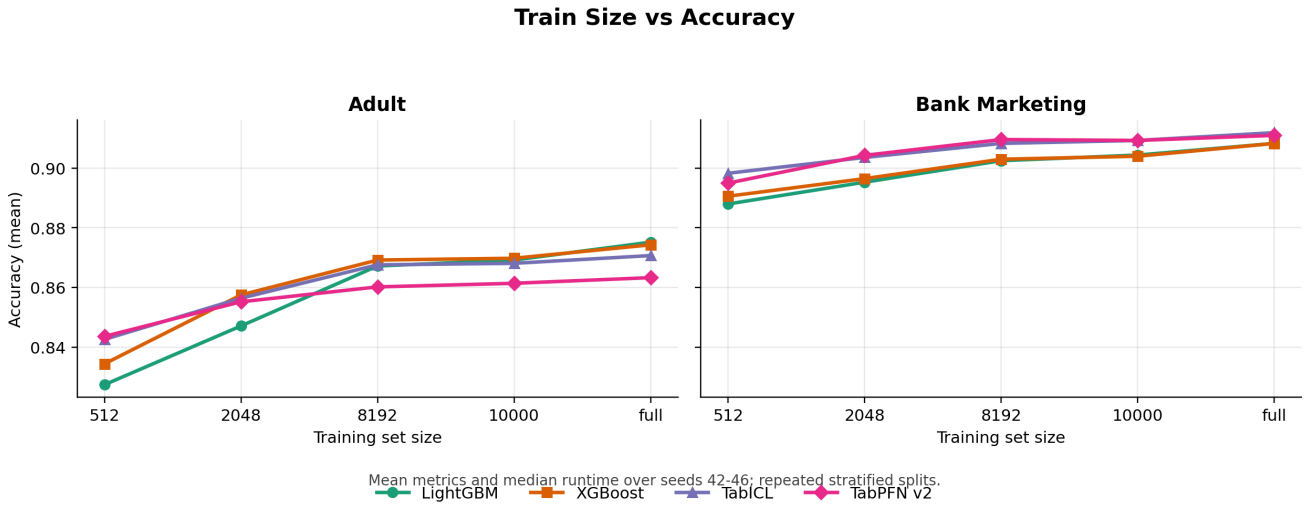

图 1. Train size 与 accuracy 的关系。 图中展示 Adult 和 Bank Marketing 上 seeds 42 到 46 的 mean accuracy。更大的训练集通常会提高 accuracy；Adult 上树模型仍然最强，而 Bank Marketing 上 TabICL 变得更有竞争力。图中未画 error bars；标准差可在 summary CSV 中查看。

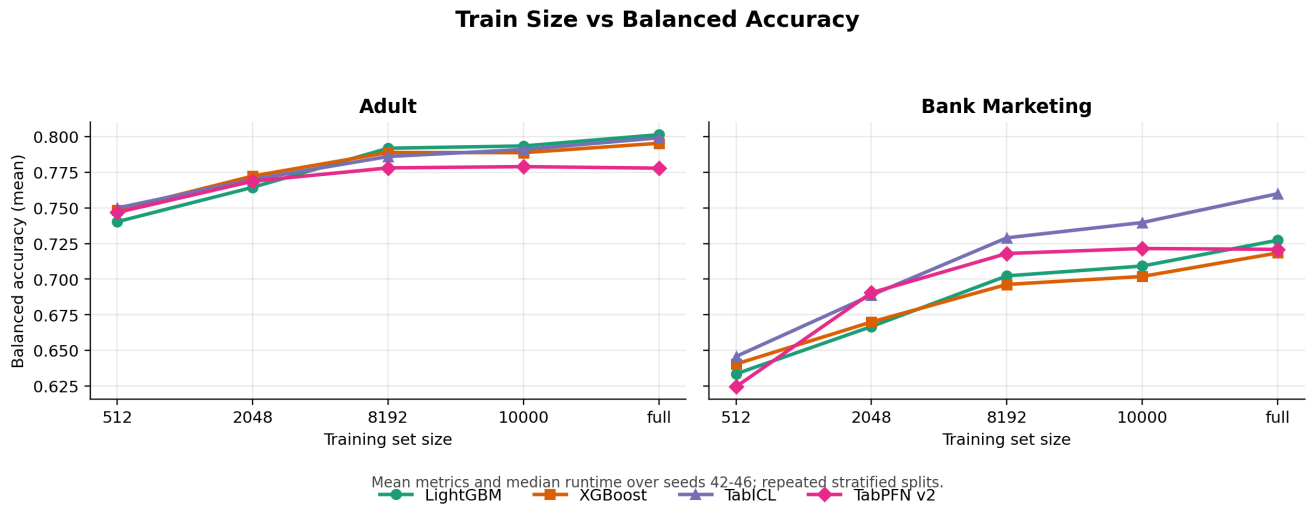

图 2. Train size 与 balanced accuracy 的关系。 图中展示 seeds 42 到 46 的 mean balanced accuracy。这个指标突出少数类表现，尤其是在 Bank Marketing 上，TabICL 从更大的 train sizes 中获得的收益比单看 accuracy 更明显。图中未画 error bars；标准差可在 summary CSV 中查看。

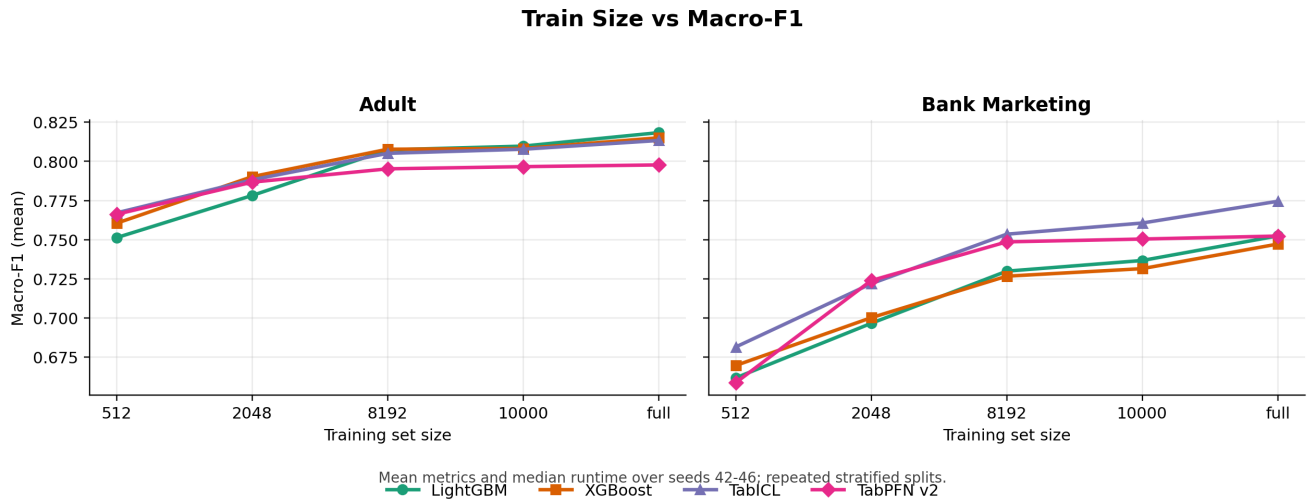

图 3. Train size 与 macro-F1 的关系。 图中展示 seeds 42 到 46 的 mean macro-F1。Macro-F1 进一步确认 dataset-dependent pattern：Adult 仍然更有利于 boosted trees，而 Bank Marketing 上 TabICL 拥有最强的 full-train imbalance-aware result。图中未画 error bars；标准差可在 summary CSV 中查看。

在 Adult 上，更大的 train size 通常会提升所有模型，但树模型收益更清楚。LightGBM 的 macro-F1 从 512 examples 下的 0.7513 上升到 full training size 下的 0.8183。TabICL 也有提升，并且仍然接近最强 baselines，但没有超过它们。TabPFN v2 在 Adult 上提升较小，并且仍然低于最强模型。

在 Bank Marketing 上，更大的 train size 会提升所有模型的 balanced accuracy 和 macro-F1。TabICL 达到最强 full-train macro-F1，数值为 0.7745。这个数据集最清楚地说明为什么只看 accuracy 不够：不同模型的 accuracy 可能接近，但 balanced accuracy 和 macro-F1 会有更明显差异。

Table 2 展示了选定的 scalability anchors。该表只保留 512 和 full 设置，使端点变化更容易阅读；Figures 1 到 3 展示完整 train-size curves。

表 2. 选定 train-size scalability anchors。

数据集	Train Size	模型	Accuracy	Balanced Accuracy	Macro-F1	Median Total Seconds
Adult	512	LightGBM	0.8274	0.7403	0.7513	0.1629

数据集	Train Size	模型	Accuracy	Balanced Accuracy	Macro-F1	Median Total Seconds
Adult	512	TabICL	0.8426	0.7499	0.7671	3.2788
Adult	512	TabPFN v2	0.8436	0.7468	0.7662	2.7220
Adult	512	XGBoost	0.8344	0.7485	0.7605	0.1297
Adult	full	LightGBM	0.8752	0.8013	0.8183	0.8572
Adult	full	TabICL	0.8707	0.7991	0.8133	22.3303
Adult	full	TabPFN v2	0.8633	0.7778	0.7977	84.1770
Adult	full	XGBoost	0.8743	0.7953	0.8150	1.2079
Bank Marketing	512	LightGBM	0.8880	0.6336	0.6618	0.1872
Bank Marketing	512	TabICL	0.8983	0.6458	0.6815	3.6889
Bank Marketing	512	TabPFN v2	0.8950	0.6246	0.6587	2.7932
Bank Marketing	512	XGBoost	0.8906	0.6405	0.6697	0.1399
Bank Marketing	full	LightGBM	0.9083	0.7273	0.7524	0.7195
Bank Marketing	full	TabICL	0.9119	0.7599	0.7745	20.1147
Bank Marketing	full	TabPFN v2	0.9110	0.7209	0.7523	80.3920
Bank Marketing	full	XGBoost	0.9083	0.7184	0.7472	0.8875

端点视角支持两个结论。第一，更多训练数据通常会帮助预测指标。第二，runtime increase 具有明显的 model-dependent 特征：树模型仍然便宜，而 foundation models 会变得昂贵得多。

Runtime 分析

Runtime 是本项目中非常重要的实际 tradeoff。Figure 4 总结了 train-size grid 上的 median total runtime。

Table 1 和 scalability analysis 来自不同实验输出文件。预测指标在共享 split protocol 下可以直接比较，但 runtime medians 应理解为本地实际计时，不同 rerun 之间可能波动，尤其是使用 GPU 的 foundation-model runs。

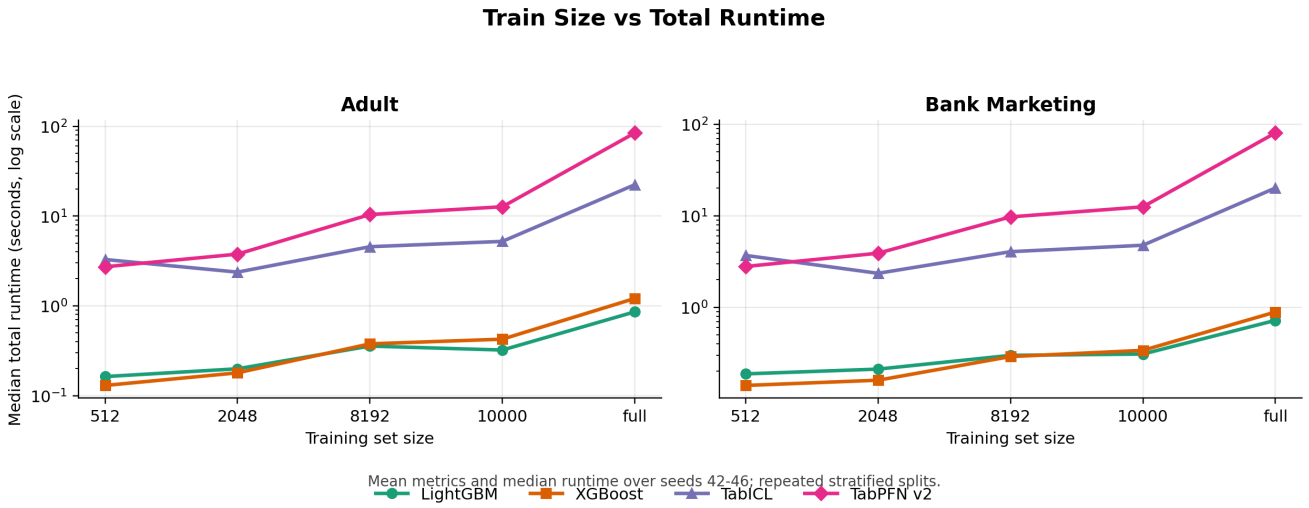

图 4. Train size 与 median total runtime 的关系。 图中展示 seeds 42 到 46 的 median total runtime，并使用 log scale。树模型保持在亚秒到一秒左右的范围；TabICL 更慢，但仍然远快于 TabPFN v2；TabPFN v2 在较大 train sizes 下成为最昂贵的模型。

树模型始终很快。在主线 summary 中，即使使用 full training size，LightGBM 和 XGBoost 也大致保持在亚秒到约一秒的运行时间范围。这使它们成为非常强的 practical baselines。

TabPFN v2 慢得多。在 scalability results 中，full train size 下它在 Adult 上的 median total runtime 约为 84.1770 秒，在 Bank Marketing 上约为 80.3920 秒。这些行是有用的 engineering references，但应结合 support-range caveat 来解释。

TabICL 也比树模型慢，但比 TabPFN v2 快得多。在 scalability results 中，full train size 下 TabICL 在 Adult 上的 median total runtime 约为 22.3303 秒，在 Bank Marketing 上约为 20.1147 秒。这使 TabICL 成为 Big Plus 扩展更合适的目标：它的指标有竞争力，尤其是在 Bank Marketing 上，同时比 TabPFN v2 更实际。

因为这些 timings 是 practical mixed-device timings，所以不应把它们表述为严格的硬件归一化速度比较。它们仍然有助于回答一个课程项目问题：在这个本地设置中，每个模型的实际成本是多少？

Big Plus：TabICL 支持集选择

Big Plus 扩展聚焦于 Adult 上的 TabICL 支持集选择。动机很直接：因为 TabICL 使用 support examples 作为上下文，所以选择更小或更有代表性的支持集，可能改善效率、性能，或二者兼顾。

Phase 6 实验只使用 Adult，并使用 seeds 42、43 和 44。它比较四种 support-set strategies：

- Full Context：使用完整的 seed-specific training split，作为不受预算限制的参考。
- Random Subset：从训练 split 中无放回均匀抽样指定 budget。
- Balanced Random Subset：先按类别配额分配 support budget，然后在每个类内随机抽样。
- Balanced Prototype Retrieval：使用与 balanced random 相同的类别配额，但在 train-only retrieval space 中选择最接近类别中心的样本。

预算受限支持集大小为 512、2048 和 8192。Full Context 使用 39,073 个 support examples。Balanced Prototype Retrieval 的 retrieval space 只由训练 split 构建。它使用 train-split numeric imputation and scaling、train-split categorical imputation and one-hot encoding，并用到类别中心的 Euclidean distance。方法定义在主要 Adult 实验之前已经冻结，因此结果应被当作 ablation 来评估，而不是被当作 tuned method search。

Figure 5 直接比较 BPR 与两个 budget-fair random baselines。负柱表示 BPR 比对应 comparator 更差。

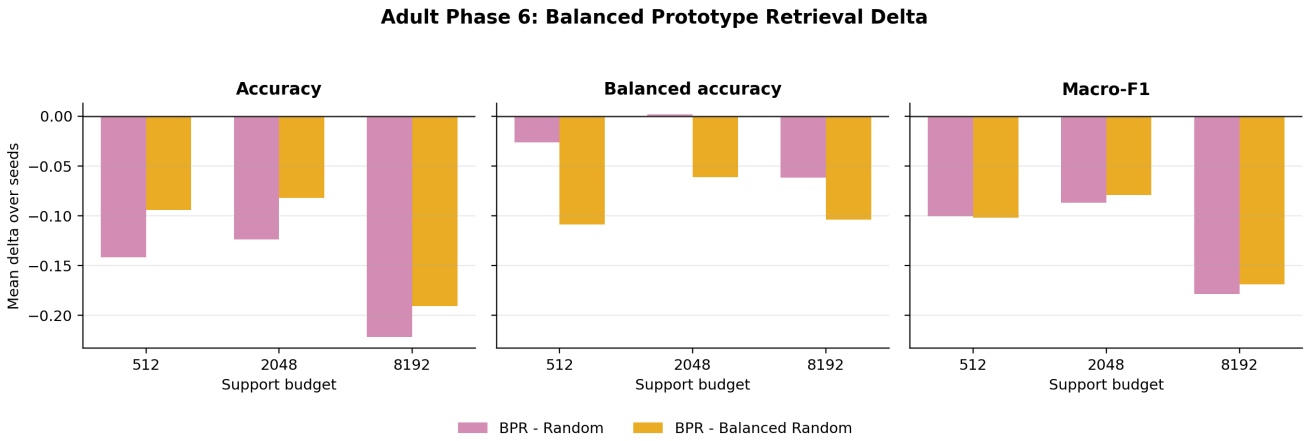

图 5. Balanced Prototype Retrieval 相对随机 baseline 的 delta。 图中展示 seeds 42、43 和 44 上的 mean metric deltas。冻结版 BPR 策略相对 Random Subset 和 Balanced Random Subset 大多为负。唯一的正值是在 budget 2048 下，相对 Random Subset 的 balanced-accuracy delta 极小为正。

支持性的 Phase 6 图也可用于查看 metric-by-budget 和 runtime：

- `results/figures/phase6_big_plus_adult_accuracy.png`
- `results/figures/phase6_big_plus_adult_balanced_accuracy.png`
- `results/figures/phase6_big_plus_adult_macro_f1.png`
- `results/figures/phase6_big_plus_adult_total_seconds_median.png`

Table 3 给出对应的 Phase 6 summary values。Metrics 是三个 seeds 的均值，runtime 是支持集已经构造完成之后的 TabICL fit+predict 时间中位数。

表 3. Phase 6 Adult 支持集选择结果。

策略	Budget	Accuracy	Balanced Accuracy	Macro-F1	Median TabICL Fit+Predict Seconds
Full Context	full	0.8722	0.7919	0.8117	45.8005
Random Subset	512	0.8438	0.7358	0.7592	3.4771
Random Subset	2048	0.8573	0.7668	0.7873	2.5291
Random Subset	8192	0.8654	0.7874	0.8038	4.6601
Balanced Random Subset	512	0.7964	0.8180	0.7610	3.4701
Balanced Random Subset	2048	0.8155	0.8295	0.7792	2.5361
Balanced Random Subset	8192	0.8344	0.8293	0.7941	4.6720
Balanced Prototype Retrieval	512	0.7020	0.7093	0.6588	3.2666
Balanced Prototype Retrieval	2048	0.7336	0.7684	0.7002	2.4829
Balanced Prototype Retrieval	8192	0.6437	0.7256	0.6253	4.7904

对于冻结的 Balanced Prototype Retrieval 方法来说，这个结果是一个 negative ablation。它没有超过 Random Subset 或 Balanced Random Subset。Balanced Random Subset 在每个 metric 和每个 budget 上都优于 BPR。相对 Random Subset，BPR 只有在 budget 2048 下有一个非常小的 positive balanced-accuracy delta，但 accuracy 和 macro-F1 仍然明显更低。

Runtime 结果仍然有价值，但必须明确它的定义。Phase 6 runtime column 记录的是支持集构造完成之后的 TabICL fit+predict 时间，不包含 BPR 的 preprocessing、class-center 计算和 distance ranking 等 support-set selection overhead。在这个模型侧计时定义下，Full Context 的 median 为 45.8005 秒，而预算受限策略大约在 2.5 到 4.8 秒范围内。因此，support-set compression 可以让 TabICL 模型执行快得多；但如果要声称完整 retrieval system 运行时间收益，还需要把支持集选择开销也计入。

正确结论不是 Big Plus “成功了”。更谨慎的结论是：support-set compression 具有实际价值，而 Balanced Random Subset 是一个很强的 baseline，未来任何 retrieval method 都必须先超过它。

补充 Missingness 鲁棒性检查

为了更直接回应 missing-value robustness，本项目增加了一个 Adult-only 小型 stress test。实验使用 train size 2048 和 seed 42，对 train/test 的 feature cells 注入确定性缺失 mask，四个模型使用同一 masked split。Table 4 报告各模型指标，以及相对 0% 注入缺失 baseline 的下降幅度。

表 4. Adult missingness robustness check，train size 2048，seed 42。

Missing Rate	Model	Accuracy	Accuracy Drop	Balanced Accuracy	Balanced Accuracy Drop	Macro-F1	Macro-F1 Drop
0.0	LightGBM	0.8508	0.0000	0.7692	0.0000	0.7835	0.0000
0.0	XGBoost	0.8603	0.0000	0.7793	0.0000	0.7959	0.0000
0.0	TabPFN v2	0.8552	0.0000	0.7707	0.0000	0.7876	0.0000
0.0	TabICL	0.8556	0.0000	0.7673	0.0000	0.7863	0.0000
0.1	LightGBM	0.8418	0.0089	0.7549	0.0144	0.7695	0.0140
0.1	XGBoost	0.8525	0.0078	0.7663	0.0130	0.7834	0.0125
0.1	TabPFN v2	0.8525	0.0027	0.7628	0.0079	0.7816	0.0061
0.1	TabICL	0.8542	0.0013	0.7616	0.0057	0.7823	0.0040
0.3	LightGBM	0.8255	0.0253	0.7213	0.0480	0.7389	0.0446
0.3	XGBoost	0.8316	0.0287	0.7243	0.0550	0.7447	0.0512
0.3	TabPFN v2	0.8337	0.0215	0.7227	0.0480	0.7450	0.0426
0.3	TabICL	0.8393	0.0163	0.7378	0.0295	0.7581	0.0282

所有模型都会随着注入缺失率升高而下降。在这个单 seed、2048 train-size 设置中，TabICL 在 30% 注入缺失下三个指标的下降幅度最小。但这只是补充 sanity check，不能扩展成系统鲁棒性结论；更完整的 missingness mechanism、categorical-cardinality shift 和更多 benchmark 数据集仍属于未来工作。

讨论

结果显示，表格模型表现具有明显 dataset-dependent 特征。Adult 更偏向 boosted-tree baselines，而 Bank Marketing 给 foundation models 更清楚的优势，尤其是在 balanced accuracy 和 macro-F1 被纳入考虑时。

结果也说明为什么 accuracy alone 不够。在 Bank Marketing control-10k 中，TabICL 和 TabPFN v2 的 accuracy 持平，但 TabICL 在 balanced accuracy 和 macro-F1 上更强。这一点很重要，因为 Bank Marketing 比 Adult 更不平衡。

Runtime 会改变实际解释。树模型既强又快。TabPFN v2 在一些设置中有竞争力，但 runtime 高得多。TabICL 提供了更好的 foundation-model tradeoff：它比树模型慢，但远快于 TabPFN v2，并且在 Bank Marketing 的 imbalance-aware metrics 上最强。

Big Plus 结果虽然是负结果，但仍然有用。它说明一个看起来合理的支持集选择规则，也就是 class-center prototype selection，并不会自动优于 random context construction。它也说明 Balanced Random Subset 是一个认真且强的 baseline。未来的 retrieval method 不只需要超过 naive random subset，还需要在相同 budgets 和 splits 下超过 balanced random sampling。

局限性

本项目只使用两个主线数据集 Adult 和 Bank Marketing，因此结果不能泛化到所有表格分类任务。

Missingness 鲁棒性检查也刻意保持较小规模：只覆盖 Adult、一个 train size 和一个 seed。它可以作为 injected feature missingness 下的 sanity check，但不是跨 missingness mechanisms、categorical-cardinality shifts 或更多 benchmark suites 的系统研究。

项目只覆盖分类任务。回归和生存分析不在范围内。

LightGBM 和 XGBoost 是 fixed strong baselines，而不是 tuned state-of-the-art baselines。更充分的超参数调优可能改变部分差距。

Runtime 是 practical mixed-device timing。树模型在 CPU 上运行，而 foundation models 可能使用 CUDA。因此，runtime 不应被解释为严格同设备 benchmark。

Repeated stratified split protocol 意味着每个 seed 有不同的测试集。在一个 seed 内，模型共享 split；但跨 seeds 时，评估是 repeated-split evaluation，而不是一个固定 held-out test set。

Full-train TabPFN v2 results 超过了更干净的 10k support-range 设置，应被当作 constrained reference results。

Phase 6 Big Plus ablation 只在 Adult 上进行，并且使用三个 seeds。它不应被解释为所有 retrieval-based support-set selection 都无效。它只说明，在当前设置中，冻结版 balanced prototype retrieval rule 没有超过强随机 baselines。

结论

本项目在 Adult 和 Bank Marketing 上比较了 tabular foundation models 和 boosted-tree baselines。主线结果显示，boosted trees 仍然非常强，尤其是在 Adult 和 runtime 上。Foundation models 在 Bank Marketing 上更有竞争力，其中 TabICL 拥有最强的 imbalance-aware metrics。

Train-size scalability 显示，更大的训练集通常会改善指标，但也会增加 runtime，尤其是对 foundation models 而言。Runtime analysis 显示出实际差距：树模型最快，TabICL 远快于 TabPFN v2，而 TabPFN v2 在较大 train sizes 下变得昂贵。

Big Plus 支持集选择实验给出了一个有价值的负结果。预算受限支持集显著降低了 TabICL fit+predict 的模型侧 runtime，但冻结版 balanced prototype retrieval strategy 没有在预测表现上超过 random subset 或 balanced random subset。补充 missingness check 显示四个模型在注入缺失下都会退化，但这个结果仍只是小规模 sanity check。最后的经验是保守的：TabICL 是 Bank Marketing 和实际扩展工作的一个有希望的 foundation-model baseline，但支持集检索方法必须先超过强 random 和 balanced random baselines，才能被称为真正的改进。